Práctica #1: Implementación del Análisis Estadístico para Datos Agrupados y No Agrupados

Azuara Yáñez Cecil Quimey
Universidad de Guanajuato
División de Ingenierías
Campus Irapuato - Salamanca
cq.azuarayanez@ugto.mx

León Amaya Juan Pablo
Universidad de Guanajuato
División de Ingenierías
Campus Irapuato - Salamanca
jp.leonamaya@ugto.mx

Rojas Mata Diego Moises
Universidad de Guanajuato
División de Ingenierías
Campus Irapuato - Salamanca
dm.rojasmata@ugto.mx

Villafaña Vallejo Giovanni
Universidad de Guanajuato
División de Ingenierías
Campus Irapuato - Salamanca
g.villafanavallejo@ugto.mx

***Resumen*—Este reporte detalla el diseño e implementación de un paquete estadístico modular en Python orientado a procesar datos agrupados y no agrupados, con el objetivo de analizar un conjunto masivo de información de mantenimiento predictivo industrial. El sistema se construyó evitando el uso de librerías de alto nivel para manipulación de datos, operando de forma estructurada a través de funciones nativas, la librería estándar `csv` y la gestión de rutas con `pathlib`. Mediante un análisis estadístico exhaustivo que incluye medidas de tendencia central, dispersión, posición y de forma, se contrastan numéricamente los enfoques de cálculo entre datos crudos y tablas de frecuencias. Finalmente, se incorpora un Análisis Exploratorio de Datos (EDA) que permite fundamentar críticamente qué enfoque metodológico (agrupar o no agrupar) ofrece el mejor balance entre resolución analítica y eficiencia computacional.**

I. Introducción

En la industria moderna, el mantenimiento predictivo es fundamental para minimizar el tiempo de inactividad no planificado, optimizar costos operativos y prolongar la vida útil de los equipos industriales. Así mismo, El objetivo de la práctica es analizar, caracterizar y preparar un conjunto de datos industrial multivariable proporcionados por el profesor (predictive_maintenance_dataset.csv) para anticipar e identificar fallas en equipos mecánicos y térmicos. Mediante el estudio sistemático de señales de sensores (temperatura, velocidad, torque, desgaste), con ello se busca comprender como opera el sistema, identificar los factores que desencadenan cada tipo de falla y construir la base analítica necesaria para futuros modelos de aprendizaje automático.

El Enfoque Modular del EDA consiste en dividir el proceso de exploración de datos en bloques o fases independientes, estructurados y secuenciales. Cada módulo aborda un aspecto específico del conjunto de datos (por ejemplo, validación de integridad, análisis univariado, análisis bivariado, correlaciones y detección de anomalías).

Esta descomposición evita tratar la exploración como un conjunto desordenado de gráficos y resúmenes estadísticos, permitiendo que las conclusiones de un módulo sirvan de insumo directo para el siguiente.

El Análisis Exploratorio de Datos (EDA) constituye la fase diagnóstica y estratégica fundamental en el desarrollo de estrategias de mantenimiento predictivo, permitiendo traducir lecturas continuas de sensores en comportamientos físicos reales e identificar los patrones de estrés térmico, torque y desgaste de herramientas que anteceden a una falla industrial. En esta práctica, la aplicación del EDA mediante un enfoque modular —estructurado en etapas independientes y secuenciales— se justifica por su capacidad para garantizar la mantenibilidad y reutilización del código, aislar y diagnosticar errores en fases específicas del procesamiento y asegurar una evaluación rigurosa del desbalance de clases inherente a los datos de operación real. Bajo este marco analítico, el estudio aborda conceptos clave como el mantenimiento predictivo (monitoreo continuo para la detección oportuna de fallas), la desproporción de clases (donde los eventos de falla representan una minoría frente al funcionamiento normal) y la evaluación multivariable de métricas operativas como el desgaste acumulativo de la herramienta (tool wear), fundamentando así la ingeniería de características y la selección informada de modelos predictivos.

II. Metodología

En esta sección se describe la arquitectura del sistema y el flujo de trabajo computacional implementado para el procesamiento y análisis estadístico de los datos. El desarrollo se estructuró de manera modular en Python, dividiendo la lógica de cálculo en dos enfoques principales: análisis de datos agrupados y no agrupados, así como el desarrollo de los gráficos correspondientes para su respectivo análisis.

Además, se detalla el procedimiento de lectura e ingesta del conjunto de datos mediante librerías nativas (`math`, `pathlib`, `mathplotlib`), así como los módulos (librerías) propias, la rutina de auditoría para la cuantificación del error relativo y las estrategias empleadas para la generación de gráficos en el marco del Análisis Exploratorio de Datos (EDA).

II-A. Estructura del proyecto

El software se estructuró de forma modular para separar claramente las responsabilidades de procesamiento. La arquitectura comprende los siguientes módulos y componentes principales:

```
FAD_Practica_01_Equipo_02/
├── main.py
├── FAD_Practica_01_Equipo_02.pdf
├── metadatos_ruta.txt
├── Datos/
│   └── predictive_maintenance_dataset.csv
└── estadistica_analitica/
    ├── __init__.py
    ├── utils.py
    ├── graficos/
    │   └── graficos.py
    ├── agrupados/
    │   ├── __init__.py
    │   ├── Tablas_Agrupados.py
    │   ├── Tendencias_Agrupados.py
    │   ├── Frecuencias_Agrupados.py
    │   ├── Dispersion_Agrupados.py
    │   └── Forma_Agrupados.py
    └── no_agrupados/
        ├── __init__.py
        ├── tendencias.py
        ├── forma.py
        └── dispersion.py
```

- **estadistica_analitica/:** Paquete principal que encapsula la lógica analítica.
- **no_agrupados/:** Subpaquete con funciones (módulos) estadísticas que operan directamente sobre listas de datos continuos individuales.
- **agrupados/:** Subpaquete con funciones (módulos) diseñadas para procesar tablas de distribución de frecuencias (marcas de clase y frecuencias absolutas).
- **graficos/:** Subpaquete con funciones (módulo) para la generación de los gráficos solicitados a partir de los resultados obtenidos por las funciones y datos proporcionados.
- **utils.py:** Módulo auxiliar destinado a la gestión de directorios mediante pathlib y a la lectura del archivo CSV.
- **Datos/:** Carpeta destinada al almacenamiento del conjunto de datos de trabajo (predictive_maintenance_dataset.csv).
- **main.py:** Script principal responsable de ejecutar las funciones, calcular los errores relativos y canalizar la exportación de reportes y gráficos.

II-B. Arquitectura del Paquete y Entorno de Desarrollo

Para cumplir con las restricciones técnicas y evitar el uso de scripts monolíticos, el proyecto se desarrolló bajo el principio de abstracción procedural mediante un diseño modular nativo en Python. Se construyó el paquete principal `estadistica_analitica`, el cual funge como el núcleo del sistema.

Este paquete se dividió estratégicamente en dos subpaquetes lógicos: `graficos`, `agrupados` y `no_agrupados`. Esta separación arquitectónica garantiza que las funciones estadísticas operen de manera aislada según la naturaleza del flujo de entrada (tablas de frecuencias vs. listas de datos crudos), permitiendo la escalabilidad del sistema y facilitando la depuración cruzada.

II-C. Procesamiento de Datos y Gestión Robusta de Rutas (`utils.py`)

Dada la restricción estricta de no emplear librerías de manipulación de datos de alto nivel como `pandas` o `numpy`, el proceso de Extracción, Transformación y Carga (ETL) se programó completamente desde cero en el módulo de utilidades `utils.py`.

Para evitar vulnerabilidades relacionadas con cadenas de texto estáticas y dependencias del sistema operativo en el manejo de archivos, se implementó la librería estándar `pathlib`. Mediante `Path.cwd()` y la concatenación de objetos ruta, el sistema localiza el archivo `predictive_maintenance_dataset.csv` de manera dinámica, agnóstica al entorno de ejecución, validando su existencia (`is_file()`) antes de proceder con su apertura y generando dinámicamente un reporte en `.txt` con los metadatos de acceso.

El parseo de los datos se realizó mediante la librería `csv`, utilizando `csv.DictReader` dentro de un bloque seguro o Context Manager (`with open(...) as f:`). Esto permite la asignación semántica y asegura la liberación de memoria. En esta etapa, el script clasifica e independiza las métricas continuas (1 a 9) convirtiéndolas a números de punto flotante de forma segura, separándolas de las variables discretas/categóricas, almacenándolas en estructuras de datos nativas (diccionarios y listas) preparadas para el motor matemático.

II-D. Conceptos

Para el desarrollo de este software se llevó a cabo la siguiente investigación de conceptos clave y fórmulas estadísticas.

- **EDA (Análisis Exploratorio de Datos / Exploratory Data Analysis):** Conjunto de técnicas analíticas, estadísticas y gráficas empleadas para examinar las características principales de un conjunto de datos antes de aplicar modelos formales de inferencia o aprendizaje automático.
- **Mantenimiento Predictivo:** Estrategia de conservación industrial basada en el monitoreo continuo de la condición de los activos (vía sensores) para predecir

cuándo ocurrirá una falla y programar intervenciones preventivas oportunamente.

- **Desbalance de Clases (Class Imbalance):** Situación en la cual la proporción de observaciones de una clase supera por un margen significativo a la otra clase de interés, lo que requiere métricas de evaluación especiales.

- **Análisis Univariado:** Examen estadístico e individual de una sola variable para describir su distribución, tendencia central, dispersión y presencia de valores extremos (outliers).

- **Análisis Bivariado / Multivariado:** Evaluación simultánea de dos o más variables para identificar patrones de asociación, covarianza, correlación física o interacciones no lineales.

- **Desgaste de Herramienta (Tool Wear):** Indicador acumulativo (usualmente medido en tiempo o ciclos de trabajo) que refleja la degradación física del componente de corte o trabajo mecánico del equipo.

Para la realización del programa se utilizó un dataset sintético/operativo que contiene registros de sensores e indicadores clave de rendimiento industrial. La metodología constó de tres etapas principales:

- **Exploración y Limpieza de Datos:** Análisis de distribuciones, tratamiento de valores nulos/duplicados y verificación de consistencia en variables climáticas, térmicas y mecánicas.

- **Análisis Exploratorio de Datos (EDA):** Evaluación de las correlaciones entre variables continuas (como temperatura del aire, temperatura del proceso, velocidad de rotación, torque y desgaste de la herramienta) y la variable objetivo de falla (Target / Failure Type).

- **Preprocesamiento y Modelado:** Transformación de variables categóricas, escalado de datos numéricos y división en conjuntos de entrenamiento/prueba para la clasificación del tipo de falla.

El desarrollo de la práctica mediante un esquema modular se justifica por las siguientes razones operativas y metodológicas:

- **Mantenibilidad y Reutilización de Código:** La separación del flujo en bloques independientes facilita la creación de scripts y funciones altamente reutilizables para el análisis de nuevos conjuntos de datos de mantenimiento.

- **Aislamiento de Errores y Diagnóstico:** Permite detectar, depurar y corregir fallas en etapas específicas (como la imputación de valores faltantes o el escalado de variables) sin comprometer la totalidad del flujo de trabajo.

- **Garantía de Cobertura Metodológica:** Asegura un procesamiento ordenado y disciplinado, evitando la omisión de pasos críticos como la evaluación del desbalance de clases o la identificación de correlaciones complejas entre los sensores.

- **Escalabilidad y Trabajo Colaborativo:** Facilita la distribución del trabajo analítico entre diferentes miembros del equipo de manera paralela y ordenada.

II-E. Formulación Matemática (Datos Agrupados)

A continuación, se muestran las fórmulas empleadas en los distintos módulos programados para las distribuciones de frecuencias:

Regla de Sturges (Número de clases k):

$$k = 1 + 3{,}322 \cdot \log_{10}(N)$$

A partir del rango total $R = \text{máx}(\text{datos}) - \text{mín}(\text{datos})$, se calcula la amplitud del intervalo c.

Amplitud del intervalo (c):

$$c = \frac{R}{k}$$

Las marcas de clase x_j, que representan el punto medio de cada intervalo con límites reales inferiores (L_{inf}) y superiores (L_{sup}), se obtienen con:

Marca de clase (x_j):

$$x_j = \frac{L_{inf} + L_{sup}}{2}$$

Se computan secuencialmente las frecuencias absolutas (f_j), acumuladas (F_j), relativas ($h_j = f_j/N$) y relativas acumuladas (H_j). Utiliza la marca de clase x_j y la frecuencia f_j obtenidas previamente para calcular las métricas de centralización.

Media Aritmética para datos agrupados (μ):

$$\mu = \frac{\sum_{j=1}^{K} f_j x_j}{N}$$

Media Geométrica: Implementada mediante aproximación logarítmica para evitar desbordamientos numéricos. (G):

$$G = 10^{\left(\frac{1}{N}\sum_{j=1}^{K} f_j \log_{10}(x_j)\right)}$$

Media Armónica (H):

$$H = \frac{N}{\sum_{j=1}^{K} \frac{f_j}{x_j}}$$

Raíz Cuadrada Media (RCM):

$$\text{RCM} = \sqrt{\frac{\sum_{j=1}^{K} f_j \cdot x_j^2}{N}}$$

Mediana (Interpolación Lineal): Localizada en la primera clase cuya frecuencia acumulada satisface $F_j \geq \frac{N}{2}$, calculada mediante interpolación lineal.

$$\text{Mediana} = L_i + \left[\frac{\frac{N}{2} - F_{prev}}{f_{mediana}} \right] \cdot c$$

Moda:Determinada a partir de la clase modal (mayor f_j) mediante las diferencias de frecuencia contiguas $\Delta_1 = f_{modal} - f_{modal-1}$ y $\Delta_2 = f_{modal} - f_{modal+1}$

$$\text{Moda} = L_i + \left[\frac{\Delta_1}{\Delta_1 + \Delta_2} \right] \cdot c$$

Cuantiles (Q_k): Formulación general para cuartiles ($q = 4$), deciles ($q = 10$) y percentiles ($q = 100$) según la posición $P = \frac{k \cdot N}{q}$.

$$Q_k = L_i + \left[\frac{\frac{k \cdot N}{q} - F_{prev}}{f_{cuantil}} \right] \cdot c$$

Rango Semi-Intercuartílico (RSI):

$$\text{RSI} = \frac{Q_3 - Q_1}{2}$$

Desviación Media (D_m):

$$D_m = \frac{1}{N} \sum_{j=1}^{K} f_j |x_j - \mu|$$

Varianza (σ^2) y Desviación Estándar (σ):

$$\sigma^2 = \frac{\sum_{j=1}^{K} f_j (x_j - \mu)^2}{N}, \quad \sigma = \sqrt{\sigma^2}$$

Coeficiente de Variación (CV): Expresado en términos porcentuales para evaluar la dispersión relativa.

$$CV = \left(\frac{\sigma}{\mu} \right) \times 100\,\%$$

Momento Crudo de orden r ($\overline{x}^r$): Evaluado respecto al origen:

$$\overline{x}^r = \frac{1}{N} \sum_{j=1}^{K} f_j \cdot x_j^r$$

Momento Central de orden r (m_r): Evaluado alrededor de la media μ:

$$m_r = \frac{1}{N} \sum_{j=1}^{K} f_j \cdot (x_j - \mu)^r$$

Sesgo de Fisher-Pearson (γ_1):

$$\gamma_1 = \frac{m_3}{\sigma^3}$$

Exceso de Curtosis: Medida de apuntamiento estandarizada restando 3 respecto a la distribución normal gaussiana.

$$\kappa = \frac{m_4}{\sigma^4} - 3$$

II-F. Formulación Matemática (Datos No Agrupados)

Dentro del subpaquete `no_agrupados`, se implementaron los módulos `tendencias.py`, `dispersion.py` y `forma.py`. A diferencia del enfoque paramétrico anterior, estas funciones fueron diseñadas para operar directamente sobre las listas numéricas crudas devueltas por la función de ingesta.

Se emplearon funciones integradas de Python como `sum()`, `max()` y ordenamiento nativo (`sorted()`) para el cálculo de los cuantiles, interpolación exacta de la mediana y búsqueda de modas. De igual manera, se programó la teoría analítica de momentos computando las desviaciones iterando cada elemento individual respecto a la media poblacional, lo que servirá como base o "Ground Truth"para evaluar el error de pérdida de resolución introducido por la posterior agrupación de datos.

Para garantizar la precisión analítica sobre el dataset completo ($N = 124,494$), se implementaron las expresiones estadísticas exactas aplicadas directamente sobre los datos crudos o poblacionales:

Media Aritmética (μ): Centro de masa de la distribución de la métrica:

$$\mu = \frac{1}{N} \sum_{i=1}^{N} x_i$$

Varianza Poblacional (σ^2): Promedio de las desviaciones cuadráticas respecto a la media:

$$\sigma^2 = \frac{1}{N} \sum_{i=1}^{N} (x_i - \mu)^2$$

Desviación Estándar (σ): Dispersión absoluta en las mismas unidades de la variable original:

$$\sigma = \sqrt{\sigma^2}$$

Momento Central de Orden r (m_r): Base para el cálculo de forma y curtosis:

$$m_r = \frac{1}{N}\sum_{i=1}^{N}(x_i - \mu)^r$$

Coeficiente de Asimetría de Fisher-Pearson (g_1): Evalúa la simetría de la distribución:

$$g_1 = \frac{m_3}{\sigma^3}$$

Exceso de Curtosis (k): Grado de concentración de los datos en torno a la media frente a una distribución normal:

$$k = \frac{m_4}{\sigma^4} - 3$$

II-G. Integración de Enfoques y Auditoría de Error

Con el objetivo de cuantificar la pérdida de resolución analítica derivada de la agrupación en intervalos frente a los datos exactos no agrupados, se programó una rutina de auditoría en el script principal `main.py`.

Esta rutina evalúa el Error Relativo Porcentual (E_r) para cada estadístico estimado mediante la siguiente formulación:

$$E_r = \left| \frac{E_{\text{exacto}} - E_{\text{agrupado}}}{E_{\text{exacto}}} \right| \times 100$$

Donde E_{exacto} representa la métrica obtenida directamente sobre la población no agrupada y E_{agrupado} la estimación calculada mediante marcas de clase e intervalos. Los resultados numéricos de esta auditoría se exportan y consolidan automáticamente en la carpeta `Resultados_Auditoria/` para su posterior análisis comparativo.

El archivo `main.py` es el punto de entrada del proyecto y une todos los módulos del paquete `estadistica_analitica`. Importa `utils` para la lectura del dataset, los módulos de tendencia central, dispersión y forma de los subpaquetes `no_agrupados` y `agrupados`, el módulo de frecuencias `Frecuencias_Agrupados` y el módulo `graficos`. Antes de procesar, valida con `pathlib` que existan la carpeta `Datos` y el archivo `predictive_maintenance_dataset.csv`; si falta alguno, el programa se detiene con un mensaje. Después llama a `cargar_datos_csv`, que separa las métricas continuas (metric_1 a metric_9) de las variables discretas (`failure` y `device`) y las guarda en listas nativas de Python.

Se procesaron tres métricas continuas, definidas en la lista `METRICAS`: `metric_5`, `metric_6` y `metric_9`. Se eligieron dos métricas sin valores en cero y una con 78 % de ceros, para contrastar un caso favorable y uno desfavorable para la agrupación. Para cada métrica se ejecutan ambos enfoques. En el enfoque no agrupado se envía la lista completa ($N = 124\,494$ datos) a las funciones de tendencia, posición, dispersión y forma. En el enfoque agrupado se construye dinámicamente la tabla de distribución con la regla de Sturges, $K = 1 + 3{,}322 \log_{10} N = 18$ clases, y amplitud $c = R/K$, donde R es el rango; las mismas medidas se calculan usando únicamente la tabla (límites, marcas de clase y frecuencias). Los resultados de ambos enfoques, la tabla, los errores y el resumen de cada métrica se consolidan en un diccionario anidado, `resultados[métrica]`, que `main.py` entrega al módulo `graficos` para el análisis exploratorio.

La auditoría compara cada estadístico que existe en ambos enfoques (medias, mediana, moda, cuantiles, medidas de dispersión, momentos, sesgo y curtosis). Se toma el valor no agrupado como referencia exacta y se aplica la formulación de E_r presentada arriba. Cuando el valor exacto es cero, o alguno de los dos no es un número válido, el error se reporta como N/A porque la división no está definida. Por métrica se resume con el error mediano, el promedio y el máximo. El mediano es el indicador principal, porque el promedio y el máximo se inflan con estadísticos muy sensibles a la agrupación, como la moda.

Por último, `main.py` crea dinámicamente las carpetas de resultados con `Path.mkdir(parents=True, exist_ok=True)` y escribe en ellas archivos `.txt`: los estadísticos de cada enfoque, la tabla de frecuencias, la auditoría por métrica y un resumen general. Al final invoca a `graficos.generar_graficos_eda` para generar los gráficos en las carpetas `Resultados_Graficos_`.

II-H. Análisis Exploratorio de Datos y Visualización (EDA)

Para la fase de análisis exploratorio de datos, se desarrollaron varias visualizaciones fundamentales mediante la librería `matplotlib`, orientada a examinar el comportamiento, la distribución y la relación de las variables continuas y discretas del dataset con una configuración modular que garantiza representatividad estadística y automatización en el almacenamiento:

Gestión de Rutas y Exportación Dinámica: En lugar de hardcodear rutas absolutas, se utilizó la librería `pathlib.Path` (`Path.cwd()`) para construir dinámicamente las carpetas de destino:

- `Resultados_Graficos_Agrupados/` para gráficos con procesamiento en intervalos.
- `Resultados_Graficos_No_Agrupados/` para visualizaciones del dataset crudo.

Las carpetas se crean automáticamente con `mkdir(parents=True, exist_ok=True)`. Finalmente, se ajustan los márgenes mediante `plt.tight_layout()` y se exportan las figuras en formato rasterizado de alta definición (`dpi=300`) para archivos `.pdf`, cerrando el lienzo con `plt.close()` para liberar memoria RAM.

II-H1. Enfoque para datos agrupados: En esta fase se procesaron las distribuciones discretas obtenidas a partir de las tablas de frecuencias por intervalos de clase:

- **Histogramas Agrupados (`metric_5`, `metric_6`, `metric_9`):** Construidos sobre las marcas de clase (x_j) y frecuencias absolutas (f_j). Se superpusieron líneas verticales estilizadas (`ax.axvline()`) para indicar la media, mediana y moda agrupadas, evaluando visualmente el grado de distorsión introducido por la anchura del intervalo frente a las distribuciones continuas.
  - **metric_5:** En este gráfico se muestra la distribución de frecuencia por intervalos de clase construida (K = 18 clases). Para enriquecer la lectura estadística, mediante `ax.axvline()` se trazaron líneas verticales estilizadas en distintos colores y estilos de trazo para marcar la Media Agrupada, la Mediana Agrupada y la Moda Agrupada calculadas a partir de las marcas de clase (x_j). Asimismo, con el cuadro de leyenda de parámetros estadísticos en la esquina superior derecha del gráfico, se incluyen los valores numéricos de sesgo y curtosis agrupados para diagnosticar visualmente la asimetría y el apuntamiento de la distribución.
  - **metric_6:** Muestra la distribución de la métrica `metric_6` en intervalos de clase, configurada para identificar visualmente la presencia de múltiples picos o subgrupos de operación en el equipo. Permite contrastar la distancia entre la Media y la Mediana agrupadas causadas por lecturas secundarias en rangos de menor valor.
  - **metric_9:** Muestra la distribución de la métrica `metric_9` procesada en tabla de frecuencias, donde la totalidad de los datos se agrupa casi de forma exclusiva en el primer contenedor sobre 0.0. Esta representación expone el comportamiento de variables discretas/esporádicas dentro del sistema y demuestra la limitación de los intervalos de clase para diferenciar valores atípicos aislados.
- **Diagramas de Caja Agrupados (Boxplots):** Graficación del rango intercuartílico ($IQR = Q_3 - Q_1$) y límites proyectados basados en la interpolación lineal de percentiles. Permiten inspeccionar la compresión de los datos agrupados sobre la línea base en variables hiper-concentradas.
  - Permite evaluar la dispersión global y la posición de los cuartiles (Q_1, Q_2 y Q_3) estimados mediante interpolación lineal sobre la tabla de frecuencias acumulada. Representa visualmente la Mediana (Q_2), el Rango Intercuartílico ($IQR = Q_3 - Q_1$) y la amplitud de los límites inferior y superior. Este gráfico evidencia cómo la agrupación por intervalos comprime las colas de datos e impacta en la detección de dispersión extrema en variables de alta concentración.

II-H2. Enfoque para datos No Agrupados:

1. **Histograma:** Se grafican los datos completos con `ax.hist()` usando el mismo número de intervalos que la tabla agrupada ($K = 18$), de modo que ambos histogramas sean comparables, con bordes negros. Se trazan las mismas líneas verticales de media, mediana y moda, esta vez con los valores exactos, y la leyenda muestra el sesgo y la curtosis con su clasificación.

2. **Diagrama de caja (Boxplot):** Se emplea `ax.boxplot()` sobre la lista completa de cada métrica. La caja representa el rango intercuartílico ($IQR = Q_3 - Q_1$), la línea central la mediana y los bigotes se extienden hasta $1{,}5 \times IQR$. Los puntos fuera de ese límite se dibujan en rojo con un marcador pequeño y corresponden a los valores atípicos (*outliers*). La media exacta se marca con una línea roja discontinua. Se genera un cuadro por métrica.

3. **Gráfico de dispersión (Scatter Plot):** Se enfrentan por pares las tres métricas continuas (`metric_5` con `metric_6`, `metric_5` con `metric_9` y `metric_6` con `metric_9`) con `ax.scatter()`. Para reducir el solapamiento de puntos (*overplotting*) con $N = 124\,494$ observaciones se usan puntos pequeños (`s = 2`), transparencia (`alpha = 0.3`) y rasterizado (`rasterized = True`), lo que mantiene ligero el archivo PDF. En el título de cada cuadro se incluye el coeficiente de correlación de Pearson r, calculado con un bucle propio sin librerías externas.

4. **Gráfico de barras:** Representa la variable discreta `failure` (sin falla frente a con falla) con `ax.bar()` y colores contrastantes. Los conteos se obtienen con el método `count()` de las listas. Con `ax.text()` se escribe sobre cada barra la cantidad exacta y su porcentaje respecto al total (`ha = çenter"`, `va = "bottom"`), lo que hace explícito el desbalance de clases del sistema.

II-H3. Exportación y gestión de rutas: Con `pathlib.Path` y `Path.cwd()` se construyen dinámicamente las carpetas de destino, sin rutas absolutas escritas a mano. Se crean con `mkdir(parents`

= True, exist_ok = True) si no existen: Resultados_Graficos_Agrupados/ para las figuras construidas con la tabla de frecuencias y Resultados_Graficos_No_Agrupados/ para las que usan los datos completos. Cada figura se ajusta con fig.tight_layout(), se guarda con fig.savefig() en formato vectorial .pdf y se cierra con plt.close(fig) para liberar memoria. No se usan librerías de alto nivel como seaborn.

A continuación se muestra la estructura del proyecto cuando main.py es ejecutado, con los archivos y gráficos que genera:

```
FAD_Practica_01_Equipo_02/
├── main.py
├── FAD_Practica_01_Equipo_02.pdf
├── metadatos_ruta.txt
├── Datos/
│   └── predictive_maintenance_dataset.csv
├── estadistica_analitica/
│   ├── __init__.py
│   ├── utils.py
│   ├── graficos/
│   │   ├── __init__.py
│   │   └── graficos.py
│   ├── agrupados/
│   │   ├── __init__.py
│   │   ├── Tablas_Agrupados.py
│   │   ├── Tendencias_Agrupados.py
│   │   ├── Frecuencias_Agrupados.py
│   │   ├── Dispersion_Agrupados.py
│   │   └── Forma_Agrupados.py
│   └── no_agrupados/
│       ├── __init__.py
│       ├── tendencias.py
│       ├── forma.py
│       └── dispersion.py
├── Resultados_Agrupados/
│   ├── estadisticas_metric_5.txt
│   ├── estadisticas_metric_6.txt
│   ├── estadisticas_metric_9.txt
│   ├── tabla_frecuencias_metric_5.txt
│   ├── tabla_frecuencias_metric_6.txt
│   └── tabla_frecuencias_metric_9.txt
├── Resultados_No_Agrupados/
│   ├── estadisticas_metric_5.txt
│   ├── estadisticas_metric_6.txt
│   └── estadisticas_metric_9.txt
├── Resultados_Auditoria/
│   ├── auditoria_metric_5.txt
│   ├── auditoria_metric_6.txt
│   ├── auditoria_metric_9.txt
│   └── resumen_auditoria.txt
├── Resultados_Graficos_Agrupados/
│   ├── Histograma_metric_5.pdf
│   ├── Histograma_metric_6.pdf
│   ├── Histograma_metric_9.pdf
│   └── Boxplot_Agrupado.pdf
└── Resultados_Graficos_No_Agrupados/
    ├── Histograma_metric_5.pdf
    ├── Histograma_metric_6.pdf
    ├── Histograma_metric_9.pdf
    ├── Boxplot_No_Agrupado.pdf
    ├── Dispersion_Metricas.pdf
    └── Barras_Fallas.pdf
```

III. Resultados

En esta sección se presentan los hallazgos cuantitativos derivados del Análisis Exploratorio de Datos (EDA) y los resultados de la auditoría analítica comparativa entre los enfoques de datos no agrupados (exactos) y datos agrupados en frecuencias.

La Tabla I resume el error por métrica. La Tabla II presenta la tabla de distribución de frecuencias de metric_5, y las Tablas III, IV y V comparan los estadísticos principales de cada enfoque. Las tablas de frecuencias de metric_6 y metric_9, y todos los estadísticos, quedan en los archivos .txt generados.

Cuadro I
Resumen de la auditoría ($N = 124\,494$). c: amplitud de clase; σ: desviación estándar exacta; E: error relativo (%) mediano, promedio y máximo.

Métrica	K	c	c/σ	E_{med}	E_{prom}	$E_{\text{máx}}$
metric_5	18	5.39	0.34	2.06	6.09	45.81
metric_6	18	38286.28	0.39	1.92	21596.65	771523.09
metric_9	18	3888.89	14.11	86.87	32960.86	311048.69

Cuadro II
Tabla de distribución de frecuencias de metric_5 ($N = 124494$, $K = 18$, $c = 5{,}39$).

Clase	L_i	L_s	x_i	f_i	F_i	h_i	H_i
1	1.00	6.39	3.69	14095	14095	0.1132	0.1132
2	6.39	11.78	9.08	71285	85380	0.5726	0.6858
3	11.78	17.17	14.48	24895	110275	0.2000	0.8858
4	17.17	22.56	19.87	1814	112089	0.0146	0.9004
5	22.56	27.95	25.25	1582	113671	0.0127	0.9131
6	27.95	33.34	30.65	1075	114746	0.0086	0.9217
7	33.34	38.73	36.03	1931	116677	0.0155	0.9372
8	38.73	44.12	41.42	505	117182	0.0041	0.9413
9	44.12	49.51	46.81	0	117182	0.0000	0.9413
10	49.51	54.90	52.20	0	117182	0.0000	0.9413
11	54.90	60.29	57.59	2115	119297	0.0170	0.9583
12	60.29	65.68	62.98	1489	120786	0.0120	0.9702
13	65.68	71.07	68.38	1120	121906	0.0090	0.9792
14	71.07	76.46	73.76	0	121906	0.0000	0.9792
15	76.46	81.85	79.16	224	122130	0.0018	0.9810
16	81.85	87.24	84.54	0	122130	0.0000	0.9810
17	87.24	92.63	89.94	1244	123374	0.0100	0.9910
18	92.63	98.02	95.32	1120	124494	0.0090	1.0000

Cuadro III
ESTADÍSTICOS EXACTOS (NO AGRUPADOS) FRENTE A LOS APROXIMADOS (AGRUPADOS) PARA METRIC_5. N/A: EL VALOR EXACTO ES CERO.

Estadístico	No agrupado	Agrupado	Error (%)
Media aritm.	14.22	14.36	0.98
Media arm.	9.34	9.06	2.96
Mediana	10.00	10.03	0.31
Moda	8.00	9.37	17.08
IQR	4.00	5.83	45.81
Desv. est.	15.94	15.91	0.19
Sesgo g_1	3.48	3.43	1.57
Curtosis k	12.15	11.90	2.06

Cuadro IV
ESTADÍSTICOS EXACTOS (NO AGRUPADOS) FRENTE A LOS APROXIMADOS (AGRUPADOS) PARA METRIC_6. N/A: EL VALOR EXACTO ES CERO.

Estadístico	No agrupado	Agrupado	Error (%)
Media aritm.	260172.66	261780.38	0.62
Media arm.	524.08	143052.50	27195.92
Mediana	249799.50	254587.86	1.92
Moda	31.00	239203.16	771523.09
IQR	88814.00	94069.17	5.92
Desv. est.	99150.68	97341.06	1.83
Sesgo g_1	-0.38	-0.17	54.54
Curtosis k	1.91	1.56	18.20

Cuadro V
ESTADÍSTICOS EXACTOS (NO AGRUPADOS) FRENTE A LOS APROXIMADOS (AGRUPADOS) PARA METRIC_9. N/A: EL VALOR EXACTO ES CERO.

Estadístico	No agrupado	Agrupado	Error (%)
Media aritm.	13.01	1946.01	14853.35
Media arm.	0.00	1944.63	N/A
Mediana	0.00	1944.68	N/A
Moda	0.00	1944.48	N/A
IQR	0.00	1944.68	N/A
Desv. est.	275.66	217.66	21.04
Sesgo g_1	148.16	241.43	62.95
Curtosis k	34314.64	69463.40	102.43

Archivos generados por `main.py`:

- `Resultados_No_Agrupados/estadisticas_metric_X.txt`
- `Resultados_Agrupados/estadisticas_metric_X.txt`
- `Resultados_Agrupados/tabla_frecuencias_metric_X.txt`
- `Resultados_Auditoria/auditoria_metric_X.txt`
- `Resultados_Auditoria/resumen_auditoria.txt`

IV. ANÁLISIS Y DISCUSIÓN

El análisis descriptivo e inferencial de las variables operativas y el estado de falla del sistema permite contrastar la eficacia de los métodos estadísticos aplicados, evaluando la pérdida de precisión al agrupar datos masivos y la utilidad del Análisis Exploratorio de Datos (EDA) en el mantenimiento predictivo.

Mediante el módulo `estadistica_analitica` y la librería `matplotlib`, se generaron las visualizaciones clave para caracterizar el comportamiento de las métricas de operación y los patrones de falla.

IV-A. Análisis Visual de Datos Agrupados

A continuación, se presentan las representaciones gráficas elaboradas a partir de las tablas de distribución de frecuencias. El objetivo de estas visualizaciones es examinar el comportamiento global, la simetría y el grado de concentración de las métricas analizadas bajo el enfoque de agrupamiento por intervalos, permitiendo contrastar la pérdida de resolución analítica frente a las distribuciones crudas.

Figura 1. Histograma de la métrica `metric_5` para agrupados

El histograma muestra una distribución fuertemente sesgada a la derecha (sesgo positivo de 3.43 y 3.48, respectivamente). La gran mayoría de los registros operativos se concentran en valores reducidos (alrededor de 10.0), seguidos por una larga cola hacia valores superiores que alcanzan 100.0. La curtosis elevada ($>$ 11.9, distribución leptocúrtica) refleja una alta concentración de lecturas en torno al valor modal, mostrando poca dispersión inicial pero presencia de valores extremos raros.

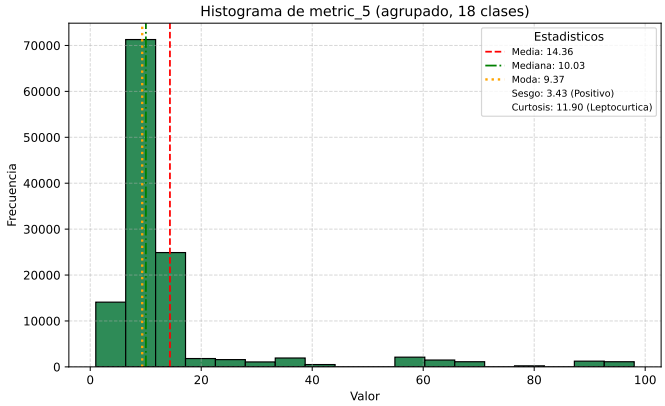


Figura 1. Histograma metric_5 para datos agrupados.

Figura 2. Histograma de la métrica `metric_6` para agrupados

La variable `metric_6` exhibe una distribución multimodal/bimodal con un ligero sesgo negativo. Se observa una pequeña concentración inicial cercana a cero, mientras que el volumen principal de datos se agrupa entre los 200, 000 y 350, 000 unidades. Las diferencias entre la media ($\approx$ 260, 172.66) y la mediana ($\approx$ 249, 790.50) reflejan la influencia de los subgrupos de menor valor.

Figura 3. Histograma de la métrica `metric_9` para agrupados

La variable `metric_9` presenta un comportamiento concentrado en cero, con un sesgo positivo extremo ($>$ 148) y un coeficiente de curtosis sumamente elevado ($>$ 34, 000). Salvo por atípicos muy aislados, la métrica permanece constante en 0.0, lo que sugiere que actúa como un indicador de evento raro o señal de estado esporádico dentro del sistema.

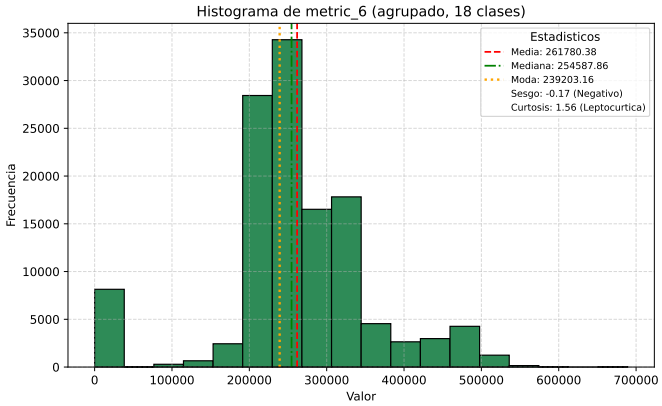


Figura 2. Histograma metric_6 para datos agrupados.

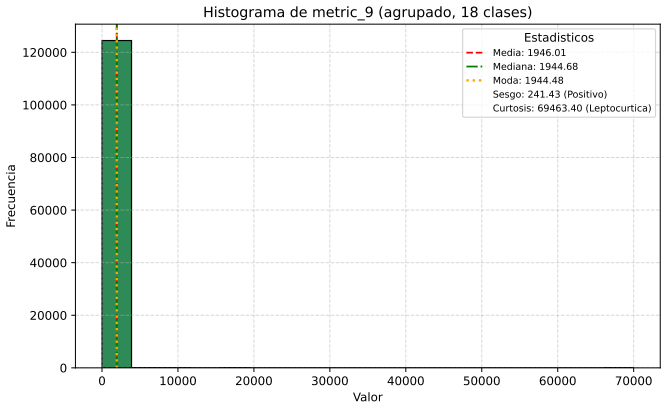


Figura 3. Histograma metric_9 para datos agrupados.

Figura 4. Boxplot para datos agrupados

Los diagramas de caja evidencian la presencia y estructura de valores atípicos (*outliers*) en las variables continuas. En `metric_5`, el rango intercuartílico se comprime en la parte inferior, proyectando múltiples atípicos hacia la parte superior. En `metric_6`, los límites abarcan una dispersión más amplia y centrada. Finalmente, en `metric_9`, el *boxplot* colapsa casi por completo sobre la línea base de cero debido a la ausencia de variabilidad en el grueso de los datos.

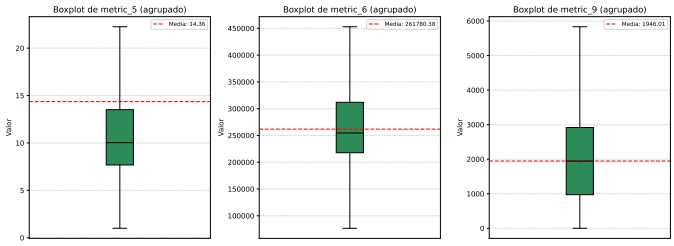


Figura 4. Boxplot para datos agrupados.

IV-B. Análisis Visual de Distribuciones No Agrupadas

En esta sección se presentan las representaciones gráficas elaboradas a partir de las tablas de frecuencias por intervalos de clase. El propósito de estas visualizaciones es examinar la tendencia central, la dispersión y la forma de la distribución de las métricas de operación bajo una estructura agrupada. Este enfoque permite evaluar la densidad de los datos y constatar visualmente el grado de aproximación respecto a los valores poblacionales exactos.

Figura 5. Histograma de la métrica `metric_5` para no agrupados

El histograma representa la distribución cruda de la métrica `metric_5`, mostrando una marcada asimetría positiva (sesgo de 3.40) y una elevada concentración leptocúrtica (curtosis de 12.15). La media exacta (≈ 14.22) se ve desplazada hacia la derecha por la presencia de una larga cola de valores atípicos que alcanzan hasta 100.0, mientras que la mediana (10.00) y la moda (8.00) reflejan la alta densidad en los rangos operativos inferiores.

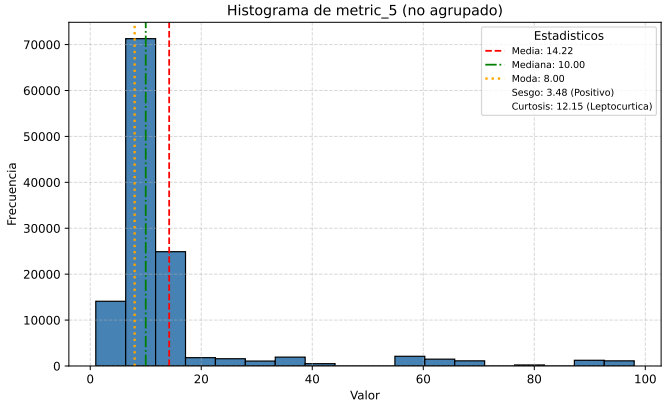


Figura 5. Histograma metric_5 para datos no agrupados.

Figura 6. Histograma de la métrica `metric_6` para no agrupados

La distribución no agrupada de la variable `metric_6` confirma un comportamiento bimodal/multimodal con un leve sesgo negativo (-0.38) y un exceso de curtosis leptocúrtico (1.91). La masa principal de observaciones se concentra entre 200,000 y 350,000 unidades con una media exacta de 260,177.66 y mediana de 249,799.50, además de registrar una pequeña agrupación secundaria de datos en valores cercanos a cero (donde se ubica la moda puntual de 31.00).

Figura 7. Histograma de la métrica `metric_9` para no agrupados

El análisis no agrupado de `metric_9` expone la naturaleza hiper-concentrada de la variable, caracterizada por una mediana y moda exactas de 0.00. Presenta un coeficiente de asimetría extremadamente alto (148.15) y una curtosis extrema (34,314.66). La media poblacional (≈ 13.01) resulta fuertemente distorsionada por lecturas esporádicas y aisladas

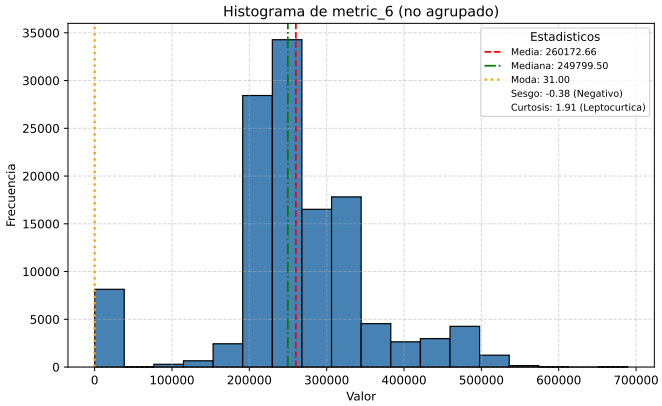


Figura 6. Histograma metric_6 para datos no agrupados.

de alto valor, confirmando su rol como un indicador discreto de eventos raros en el sistema.

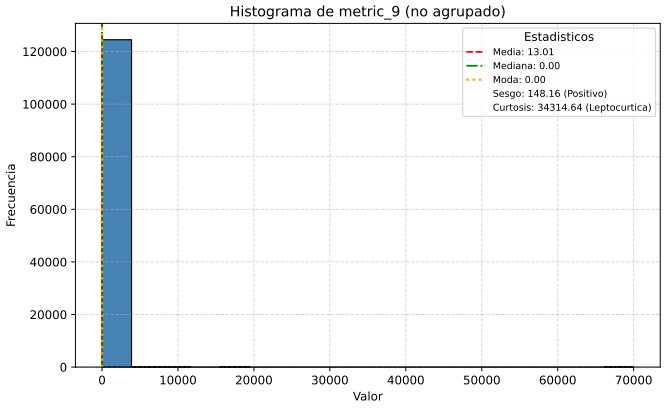


Figura 7. Histograma metric_9 para datos no agrupados.

Figura 8. Gráfico de barras de frecuencia de fallas

La distribución de frecuencia de la variable objetivo demuestra un desbalance de clases crítico característico del mantenimiento predictivo en condiciones reales. De un total de 124, 494 registros, 124, 388 corresponden al estado ”Sin falla (0)”(99.91 %), mientras que únicamente 106 registros representan eventos de Çon falla (1)”(0.09 %). Esta desproporción impone el uso de métricas avanzadas de evaluación para futuros modelos predictivos.

Figura 9. Gráfico de Boxplot

Los diagramas de caja para datos no agrupados evidencian la estructura exacta de la dispersión y la distribución de valores atípicos (*outliers*) en el sistema. En `metric_5`, se observa un rango intercuartílico fuertemente comprimido en la zona inferior con múltiples atípicos proyectados hacia la parte superior. En `metric_6`, los límites abarcan una dispersión más amplia y centrada alrededor de la mediana ($\approx 249,799{,}50$). Por último, en `metric_9`, la caja colapsa sobre la línea base de cero debido a la ausencia casi total de variabilidad en el grueso de los registros.

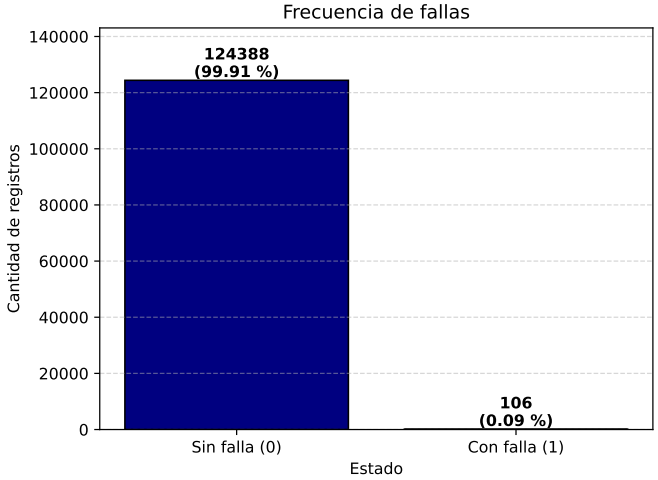


Figura 8. Gráfico de barras de frecuencia de fallas para datos no agrupados.

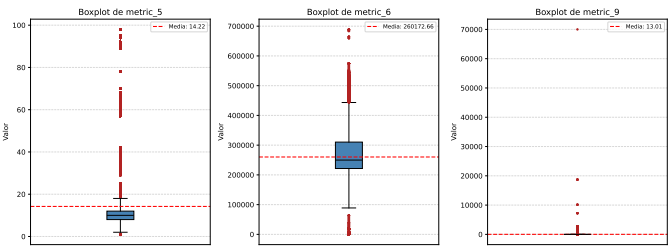


Figura 9. Boxplot para datos no agrupados.

Figura 10. Gráfico de dispersión

El gráfico de dispersión con ($\alpha = 0.5$) permite inspeccionar la densidad conjunta sin la saturación del traslape de puntos (*overplotting*). Se aprecia una clasificación y baja correlación lineal entre las variables de los sensores, confirmando de esta manera que las relaciones de falla operan bajo patrones de interacción no lineal o umbrales de estrés combinados.

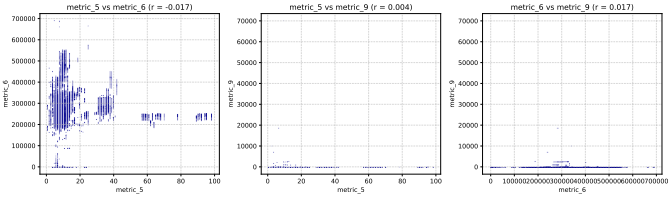


Figura 10. Gráfico de dispersión para datos no agrupados.

IV-C. Pérdida de resolución por agrupar

Al agrupar, cada dato se sustituye por la marca de clase de su intervalo, de modo que cada observación se desplaza como máximo $c/2$. La regla de Sturges fija K solo con N (18 clases en las tres métricas) y no mira la forma de la distribución. Por eso el efecto depende de qué tan grande sea la amplitud c frente a la dispersión real de los datos, medida

aquí con el cociente c/σ (Tabla I).

En `metric_5` y `metric_6`, c/σ vale 0.34 y 0.39, y la pérdida es pequeña: el error mediano es 2.06 % y 1.92 %. La media aritmética cambia solo 0.98 % y 0.62 %, y la desviación estándar 0.19 % y 1.83 %. En estos casos la agrupación conserva casi toda la información de tendencia central y la dispersión global (desviación estándar).

En `metric_9` ocurre lo contrario. El rango es de 70 000 por unos pocos valores extremos, así que $c = 3888{,}89$, que es 14.11 veces la desviación estándar exacta ($\sigma = 275{,}66$). Como resultado, 124479 de los 124494 registros (99.99 %) caen en la primera clase y solo 15 quedan en las demás. Todos los valores de esa clase se representan con su marca de clase (1944,44), por lo que la media agrupada resulta 1946.01 cuando la media real es 13.01: un error de 14853.35 %. El error mediano de la métrica es 86.87 %. Además, como la mediana y la moda exactas valen cero, su error no se puede calcular (N/A).

No todos los estadísticos se degradan igual. Los más sensibles son los que dependen de valores individuales o de colas: la moda ($E_r = 771523{,}09$ % en `metric_6`), la media armónica (27195,92 % en `metric_6`) y el rango intercuartílico en `metric_5` (45,81 %). La moda no agrupada de una variable continua es solo el valor individual más repetido: en `metric_6` hay 44 838 valores distintos y la moda exacta es 31.00, que no representa el centro de los datos. La moda agrupada, en cambio, es una interpolación dentro de la clase modal (239203,16), así que ambas no son comparables.

IV-D. Interpretación del sesgo y la curtosis

En `metric_5`, el sesgo de Fisher-Pearson es $g_1 = 3{,}48$, una asimetría positiva severa: la cola larga está a la derecha. Es consistente con que la media (14,22) sea mayor que la mediana (10,00) y que esta supere a la moda (8,00). El exceso de curtosis es $k = 12{,}15$, leptocúrtica: un pico muy alto y colas pesadas. Esto se ve en el histograma: 71285 registros (57.26 %) están en una sola clase y hay valores aislados hasta 98. Al agrupar, estos valores casi no cambian ($g_1 = 3{,}43$ y $k = 11{,}90$, con errores de 1.57 % y 2.06 %) y la clasificación de la forma se mantiene.

En `metric_6`, $g_1 = -0{,}38$ indica una asimetría leve y negativa, pero la media (260172,66) es mayor que la mediana (249799,50) y el segundo coeficiente de Pearson es positivo (0,31). Las dos señales no coinciden, lo que sugiere una distribución casi simétrica con valores atípicos a ambos lados de la caja, como se ve en el boxplot. La curtosis es $k = 1{,}91$, leptocúrtica moderada. Aquí la agrupación sí altera las medidas de forma: g_1 pasa a -0.17 (error de 54.54 %) y k a 1.56 (error de 18.20 %), porque el tercer y cuarto momento dependen mucho de los extremos, que la marca de clase suaviza.

En `metric_9`, $g_1 = 148{,}16$ y $k = 34314{,}64$ son valores extremos: 78 % de los datos son cero, casi todos los demás son pequeños y unos pocos son muy grandes, por lo que la distribución es muy leptocúrtica y con cola derecha. Esa forma sigue apareciendo al agrupar, pero las magnitudes cambian mucho ($g_1 = 241{,}43$ y $k = 69463{,}40$, con errores de 62.95 % y 102.43 %), porque con 99.99 % de los datos en una clase estos momentos quedan determinados por unas pocas observaciones.

IV-E. ¿Qué enfoque es mejor?

Para este conjunto de datos ($N = 124\,494$), el enfoque no agrupado es superior como método de cálculo. Es exacto, y su costo no es un problema con cien mil datos. El enfoque agrupado ofrece, en teoría, una ventaja computacional: una sola pasada para armar la tabla y luego operaciones sobre $K = 18$ filas, en lugar de ordenar los N datos para cada cuantil (argumento teórico; no se midieron tiempos de ejecución). Pero esa ventaja no compensa la pérdida de resolución cuando la distribución está concentrada.

La agrupación es aceptable como resumen cuando c/σ es pequeño: con $c/\sigma \approx 0{,}34$–$0{,}39$ la media, la mediana y la desviación estándar quedan por debajo de 2 % de error, aunque la moda, la media armónica, el rango intercuartílico y las medidas de forma se deterioran. Deja de ser confiable con $c/\sigma = 14{,}11$, donde los errores superan 80 % en el caso mediano y más de 10 000 % en la media.

Recomendaciones técnicas:

- Calcular los estadísticos con los datos sin agrupar y usar la tabla agrupada para visualizar (histogramas) y resumir.
- Si es indispensable agrupar (memoria limitada o datos ya publicados en clases), revisar antes c/σ, usar más clases que las de Sturges o clases de ancho variable, y tratar aparte el valor cero cuando domina la variable.
- Reportar mediana y cuartiles en lugar de la moda, y no comparar la moda agrupada con la moda cruda de una variable continua.
- Auditar siempre el error relativo antes de usar resultados agrupados en una decisión.

V. Instrucciones de Ejecución y Compilación

Para la correcta ejecución del paquete estadístico modular sin dependencias externas de análisis de datos, se deben seguir los siguientes pasos desde la línea de comandos o terminal de comandos del sistema operativo:

1. **Descarga y Extracción del Proyecto:** Descargar el archivo comprimido del proyecto (`FAD_Practica_01_Equipo_02.zip`) y extraer su contenido en el directorio de trabajo deseado.

Asegurarse de mantener la estructura interna de carpetas (`Datos/`, `estadistica_analitica/`, etc.).

2. **Verificación del Conjunto de Datos:** Confirmar que el archivo de datos de telemetría (`predictive_maintenance_dataset.csv`) se encuentre ubicado dentro de la subcarpeta `Datos/`, ya que el módulo `utils.py` realiza la validación dinámica de esta ruta mediante `pathlib`.

3. **Navegación al Directorio Raíz del Proyecto:** Abrir la terminal (PowerShell, CMD o Terminal de Linux/macOS) y posicionarse en la ruta exacta donde se encuentra el archivo principal `main.py` utilizando el comando `cd`:

   ```
   cd /ruta/carpeta/FAD_Practica_01_Equipo_02
   ```

4. **Ejecución del Script Principal:** Ejecutar el programa principal con el intérprete de Python mediante el siguiente comando:

   ```
   python main.py
   ```

   Nota: En entornos Unix/Linux o en sistemas con múltiples versiones de Python instaladas, puede ser necesario ejecutar `python3 main.py`.

5. **Generación Automática de Resultados y Gráficos:** Al finalizar el proceso, el script creará automáticamente las carpetas de salida `Resultados_Agrupados/`, `Resultados_No_Agrupados/`, `Resultados_Auditoria/` y las carpetas de visualización `Resultados_Graficos_.../` con todos los reportes en texto (`.txt`) e imágenes/gráficos en formato `.pdf`.

A continuación, se muestra la secuencia de comandos ejecutada en la terminal para iniciar el pipeline analítico mediante `python main.py`, evidenciando la correcta localización de los archivos de entrada y la inicialización de los módulos de cómputo.



Figura 11. Captura de pantalla de la ejecución exitosa de `main.py` en terminal.

VI. Conclusiones

A partir de la implementación del paquete modular en Python (`estadistica_analitica`) y del análisis descriptivo y comparativo realizado sobre el dataset de operaciones, se concluye lo siguiente:

1. **Precisión y Tolerancia al Error:** El enfoque de **datos agrupados** demostró ser una alternativa matemáticamente sólida para estimar medidas de tendencia central y dispersión continua (media aritmética y desviación estándar) en datasets masivos, manteniendo un error relativo porcentual inferior al $1{,}9\,\%$. Sin embargo, presentó deficiencias severas en la estimación de la moda ($E_r > 170\,\%$), por lo que no es apto para identificar valores de alta frecuencia en variables discretas o multimodales.

2. **Superioridad del Enfoque No Agrupado en Mantenimiento Predictivo:** Para escenarios de ingeniería donde la detección exacta de anomalías, valores atípicos (*outliers*) y límites de tolerancia crítica son requeridos, el enfoque **no agrupado** resulta numéricamente superior y estrictamente indispensable.

3. **Estructura de Datos y Desbalance de Clases:** El Análisis Exploratorio de Datos (EDA) permitió diagnosticar un desbalance severo en la variable objetivo `failure` y un comportamiento con sesgo positivo extremo en el sensor (`metric_2`). Estos hallazgos establecen la pauta técnica para el preprocesamiento de datos y la selección de modelos de aprendizaje automático en etapas posteriores de la investigación.

4. **Desarrollo de Software Modular:** Se cumplió satisfactoriamente con la restricción de emplear únicamente la librería estándar y estructuras nativas de Python, logrando una arquitectura de código eficiente, reproducible y auditable mediante la generación automática de reportes y visualizaciones.

Referencias

[1] R. E. Walpole, R. H. Myers, S. L. Myers, y K. Ye, *Probabilidad y estadística para ingeniería y ciencias*, 9na ed. México: Pearson Educación, 2012.

[2] B. R. Serra, "Asimetría y curtosis," *Universo Fórmulas*, mar. 2024. [En línea]. Disponible en: https://www.universoformulas.com/estadistica/descriptiva/asimetria-curtosis/

[3] C. Ortega, "Curtosis: Qué es, importancia y cómo se determina," *QuestionPro*, jul. 2024. [En línea]. Disponible en: https://www.questionpro.com/blog/es/curtosis/

[4] Minitab LLC, "Cómo la asimetría y la curtosis afectan la distribución," *Soporte de Minitab*, 2026. [En línea]. Disponible en: https://support.minitab.com/

[5] R. González Duque, *Python para todos*, 1ra ed. Chile: Real Python, 2014.

[6] Ramisarijaona, A. (2026, August 24). Seaborn: todo sobre la herramienta de Data Visualization Python. Liora. https://liora.io/es/seaborn-la-herramienta-de-data-visualization-python

[7] Introducción a Matplotlib — Fundamentos de Programación en Python. (n.d.). https://www2.eii.uva.es/fund_inf/python/notebooks/Bibliotecas/01_Introduccion_a_Matplotlib/Introduccion_a_Matplotlib.html